

$\sum_{t=1}^{k+1} p(w_t | w_{t-1}) \rightarrow - \sum_{t=1}^{k+1} \log p(w_t | w_{t-1})$  防止该函数连续相乘之后向下溢出, 取对数  
 OOV: (out of vocabulary) 在字典外

文本生成也可以生成摘要, 不过要进行语句检测。 pagerank 有向图  
 textrank 无向图

textrank 也可以进行关键词提取。

文本聚类 (demo-text-clustering.py): 没有标签聚类。 K-means (K 均值聚类)

距离  $\rightarrow$  相似性。迭代求解, 随机选 K 个数据为初始的聚类中心。  
 把点划分最近的那类。根据簇间距离判断, 停止迭代。目标函数

K-means: jianshu.com/p/fc91fed8c7b, 簇内尽量小, 簇间尽量大。

可计算文本相似度 文本聚类  $\rightarrow$  一般用主题模型,

词频, 主题用词, 文档向量

代码: cnblog.com/doc2vec/biading/p/887808.html

sigmoid 分类, demo-word2vec 词向量, word2vec 词向量, 一个词用一个向量表示 (13 年谷歌)

训练 (skip-gram) 和 词袋模型 (CBOW), 其中 skip-gram 用中心词预测周围词。

用周围词预测中心词。softmax 多分类。

丰度: 是指一种元素在某个自然体中重量占这个自然体总重量的相对份额。

命名实体识别, 复用 BMEs 标准集, 不构成命名实体的单词, 统一标注为 O (outside)

↓  
 现在存在的实体,

```
class ClusterAnalyzer():
    def __init__(self, document={}, word2vec={}, tfidf={}):
        pass
    def add_document(self, path):
        self.document = self.read_text(path)
    def read_txt(self):
        pass
    def text_process(self):
        pass
    def cal_tf_idf(self):
        pass
    def cal_dist(self, arr1, arr2):
        pass
    def cal_zone(self):
        pass
```

```
def save_text(self):
```

```
pass
```

```
def add_document(self, path):
```

```
for i in range(100):
```

```
if __name__ == '__main__':
```

```
data_path = os.path.join
```

```
file_path = os.path.join(path, 'f{}.txt'.format(i+1))
```

```
kmeans = ClusterAnalyzer()
```

```
self.document[str(i+1)] = f.read()
```

```
kmeans.add_document(data_path)
```

文件名字要和模块名一样的话会出错

```
print(kmeans.document)
```

```
os.path.dirname(file_)
```

有 debug 进程才有 debug probe 可以用

```
init 中再写 self.process_document = {}, self.word_table = {}
```

```
segment = DoubleArrayTrieSegment() stop_words = StopWords()
```

```
def text_process(self):
```

```
for file_id, text in self.document.items():
```

```
self.process_document[file_id] = [term.word for term in self.segment(text).seg
```

```
word_list.extend
```

```
if not self.stop_words.contains_key(term.word)]
```

```
self.word_table = list(set(word_list))
```

(self.process\_document[file\_id])

```
def fit(self, k): # 训练 kmeans
```

```
self.cal_tfidf() # 要表示为固定的维度
```

```
def cal_tfidf(self):
```

```
for file_id, text in self.process_document.items():
```

```
for word in text: tfidf_list = [0] * len(self.word_table)
```

词 文本  
word, text word, text

```
tfidf_list.insert(self.word_table.index(word), self.tf(word) * self.idf(word))
```

```
self.document[file_id] = tfidf_list
```

```
def tf(self, word):
    return text.count(word) / len(text)
```

```
def idf(self, word):
    return np.log(len(self.document) / sum(1 for self.process_document, items() if word in text))
```

```
def fit(self, k=5, num=10):
```

```
self.cal_tfidf()
self.cluster_dict = dict.fromkeys(
    range(1, k+1), {
        'center': None, 'file_id': None
    })
```

file\_id, text

process\_document

id

第i类

改为: {'center': [ ], 'file\_id': [ ]}

dict.fromkeys(seq, value)

键

对应值

随机初始k个质中心:

```
self.cluster_dict = dict.fromkeys(range(1, k+1), {'center': None, 'file_name': 'None'})
```

```
print(random.sample(range(1, len(self.process_document)), k))
```

```
for i in random.sample(range(1, len(self.process_document)), k):
```

```
self.cluster_dict[self.cluster_dict['center']] = self.document - itidf[i] → 改为str(i)
```

```
while count < num: # 计算所有点到质中心的距离
```

```
for file_id, text in self.document - itidf.items():
```

```
for cluster_id, cluster in self.cluster_dict.items():
```

```
text_dist = self.dist(text, cluster['center'])
```

```
min_dist_idx = text_dist.index(min(text_dist))
```

```
self.cluster_dict[min_dist_idx]['file_id'].append(file_id)
```

```
def cal_dist(self, arr1, arr2):
    return np.sqrt(np.sum((arr1 - arr2)**2))
```

np.array(arr1)

np.array(arr2)

用numpy更快, 底层用cpath



```

for i in range(1, k+1): # from keys: 对已创建的值都是一样的
    self.cluster_dict[i] = {'center': [], 'file_id': []} # 前面的初始化, 有问题
更新簇中心: self.update_cluster_center()
def update_cluster_center(self):
    for cluster_id, cluster in self.cluster_dict.items():
        for file_id in cluster['file_id']:
            text_ifidf.append(file_id)
text_ifidf = self.document_idf[file_id] = tfidf_list
arr_text_ifidf = np.array(text_ifidf)
np.mean(arr_text_ifidf, axis=0).
avg_cluster_center
print(avg_cluster_center.shape) 验证是 2333 维

```

```

self.cluster_dict[cluster_id]['center'] = avg_cluster_center,
更新完后, 在 while count < num 之后清除 self.cluster_dict

```

```

for i in range(1, k+1):
    self.cluster_dict[i]['file_id'] = []
def save_text(self):
    for cluster_id, cluster in self.cluster_dict.items():
        if os.path.exists(str(cluster_id)):
            os.mkdir(str(cluster_id)) # 创建文件夹
            for file_id in cluster['file_id']:
                file_path = os.path.join(str(cluster_id), '{0}.text'.format(file_id))
                with open(file_path, 'w', encoding='utf-8') as f:

```

f.write(self.document[file-id])

主题模型 分布问题 (用的较多)

现在文本分类 般用深度学习, 不用机器学习。

word2vec有上下文关系的, (在pyhanlp下statistic data中 word2vec 文档

NLU: 自然语言理解

词法分析

新词发现 (互信息 信息熵)

词性标注

句法分析 { 成分句法分析  
依存句法分析 (从人从属词指向支配词)

语义分析

词义消歧 (elmo 解决一词多义)

语义角色标注

词汇 句子 段落的向量化表示

文本分类/情感分析

文本匹配

难)

信息抽取

实体抽取 (crf)

关系抽取

事件抽取

阅读理解

(bert)

应用

机器翻译

搜索推荐 (工资高)

知识图谱

对话系统

问答系统

NLG { 文本摘要  
机器翻译