

讲师：aopu老师



## 神经网络



# 目录


- 神经网络应用场景
- 神经网络的起源
- 神经网络的基本结构



## 神经网络的应用

- 语音识别，声纹识别
- 图像应用
  - 大规模(大数据量)图片识别(聚类/分类)
  - 基于图片的搜索服务
  - 目标检测
- NLP(自然语言)，知识图谱
- 游戏、机器人、推荐系统等
- 数据挖掘(聚类、分类、回归等问题)


## 神经网络来源之人的思考



## 神经网络来源之“神经元”

- 输入： $x_1$ 、 $x_2$ 、 $x_3$ 和截距+1
- 输出：函数 $h_{w,b}(x)$ ，其中 $w$ 和 $b$ 是参数

$$h_{w,b}(x) = f(W^T x, b) = f\left(\sum_{i=1}^3 W_i x_i + b\right)$$



- 注意：函数 $f$ 被称为“**激活函数**”；常用激活函数有sigmoid(逻辑回归函数)和tanh(双曲正切函数)


$$\tanh(z) = f(z) = \frac{e^z - e^{-z}}{e^z + e^{-z}}; \quad f'(z) = 1 - (f(z))^2$$

$$\text{sigmoid}(z) = f(z) = \frac{1}{1 + e^{-z}}; \quad f'(z) = f(z)(1 - f(z))$$

## 神经网络来源之 “神经元”

$$\tanh(z) = f(z) = \frac{e^z - e^{-z}}{e^z + e^{-z}}$$

$$\text{sigmoid}(z) = f(z) = \frac{1}{1 + e^{-z}}$$



## 神经网络之感知器

- 当激活函数的返回值是<sup>①</sup>两个<sup>②</sup>固定值的时候，可以称为此时的神经网络为感知器

$$f(z) = \begin{cases} 0, & z \leq 0 \\ 1, & z > 0 \end{cases}$$

$$f(z) = \begin{cases} -1, & z \leq 0 \\ 1, & z > 0 \end{cases}$$

- 因为感知器的返回值只有两种情况，所以感知器只能解决二类线性可分的问题，感知器比较适合应用到模式分类问题中

## 神经网络之线性神经网络

- 线性神经网络是一种简单的神经网络，可以包含多个神经元；激活函数是一个线性函数，可以返回多个值，常用的激活函数为sigmoid函数和tanh函数
- 线性神经网络和感知器一样，只适合线性可分类问题；但是效果比感知器要好，而且可以做多分类问题

$$\tanh(z) = f(z) = \frac{e^z - e^{-z}}{e^z + e^{-z}}$$


$$\text{sigmoid}(z) = f(z) = \frac{1}{1 + e^{-z}}$$




bert (12层神经网络谷歌提出的  
网络模型)

## 神经网络之深度神经网络

- 增多中间层(隐层)的神经网络就叫做深度神经网络(DNN); 可以认为深度学习是神经网络的一个发展



## 神经网络直观理解之非线性可分




$x_1$	$x_2$	$z_1$	$z_2$	$h(x)$
0	0	0	0	1
0	1	0	1	0
1	0	0	1	0
1	1	1	1	1

$$W_1 = (-3, 2, 2) \quad W_2 = (-1, 2, 2) \quad W_z = (1, 2, -2)$$

$$h_w(z) = h(Wx) = \begin{cases} 0, & z < 0 \\ 1, & z \geq 0 \end{cases}$$


## 神经网络之结构



## 神经网络之传递函数(激活函数)

$$S\text{函数: } \text{sigmoid}(z) = f(z) = \frac{1}{1 + e^{-z}}$$

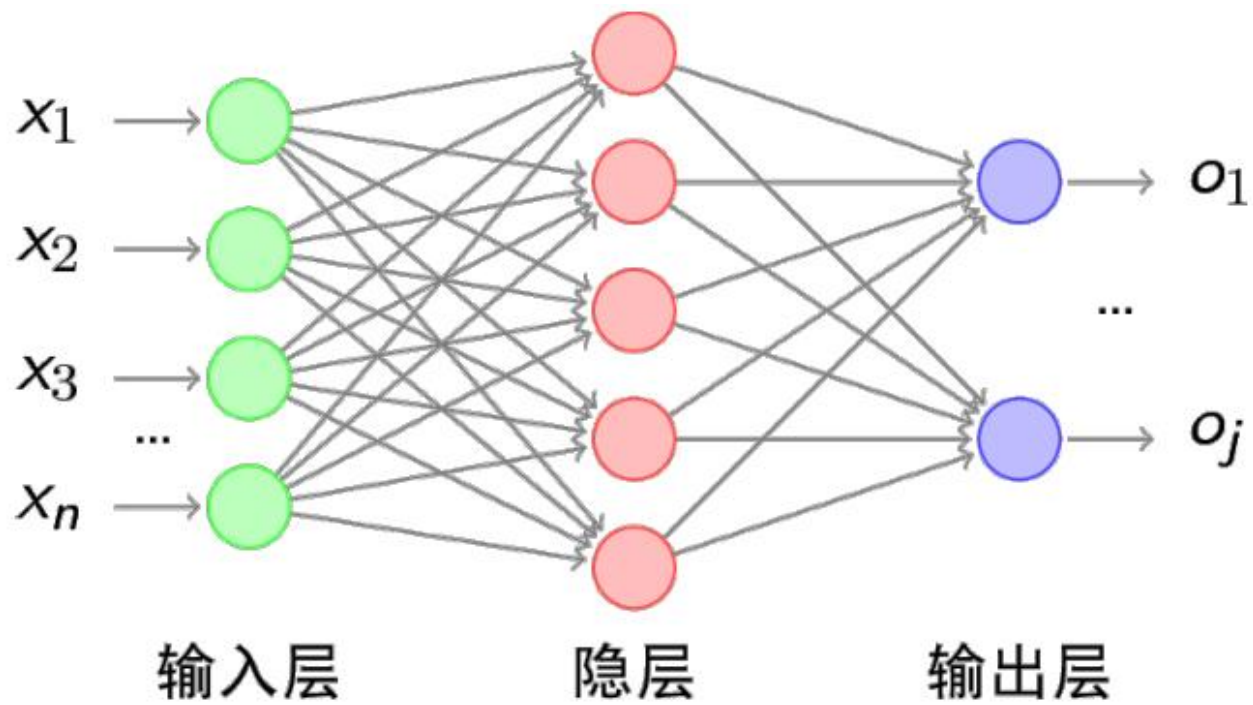
$$\text{双SS函数: } \tanh(z) = f(z) = \frac{e^z - e^{-z}}{e^z + e^{-z}}$$



## 神经网络之BP算法

# 反向误差传递技术

- BP算法也叫做 $\delta$ 算法
- 以三层的感知器为例



线性激活函数还是对线性

## 神经网络之BP算法

- 输出层误差

↑ 预测      ↓ 实际值

$$E = \frac{1}{2} (d - O)^2 = \frac{1}{2} \sum_{k=1}^{\ell} (d_k - O_k)^2$$

- 隐层的误差

↑ 预测



$$E = \frac{1}{2} \sum_{k=1}^{\ell} (d_k - f(net_k))^2 = \frac{1}{2} \sum_{k=1}^{\ell} \left( d_k - f \left( \sum_{j=1}^m w_{jk} y_j \right) \right)^2$$

- 输入层误差

$$E = \frac{1}{2} \sum_{k=1}^{\ell} \underbrace{d_k - f \left[ \sum_{j=0}^m w_{jk} f(net_j) \right]}_{\text{隐层输出}}^2 = \frac{1}{2} \sum_{k=1}^{\ell} d_k - f \left[ \sum_{j=0}^m w_{jk} f \left( \sum_{i=1}^n v_{ij} x_i \right) \right]^2$$

## 神经网络之SGD

- 误差E有了，那么为了使误差越来越小，可以采用随机梯度下降的方式进行 $\omega$ 和 $v$ 的求解，即求得 $\omega$ 和 $v$ 使得误差E最小



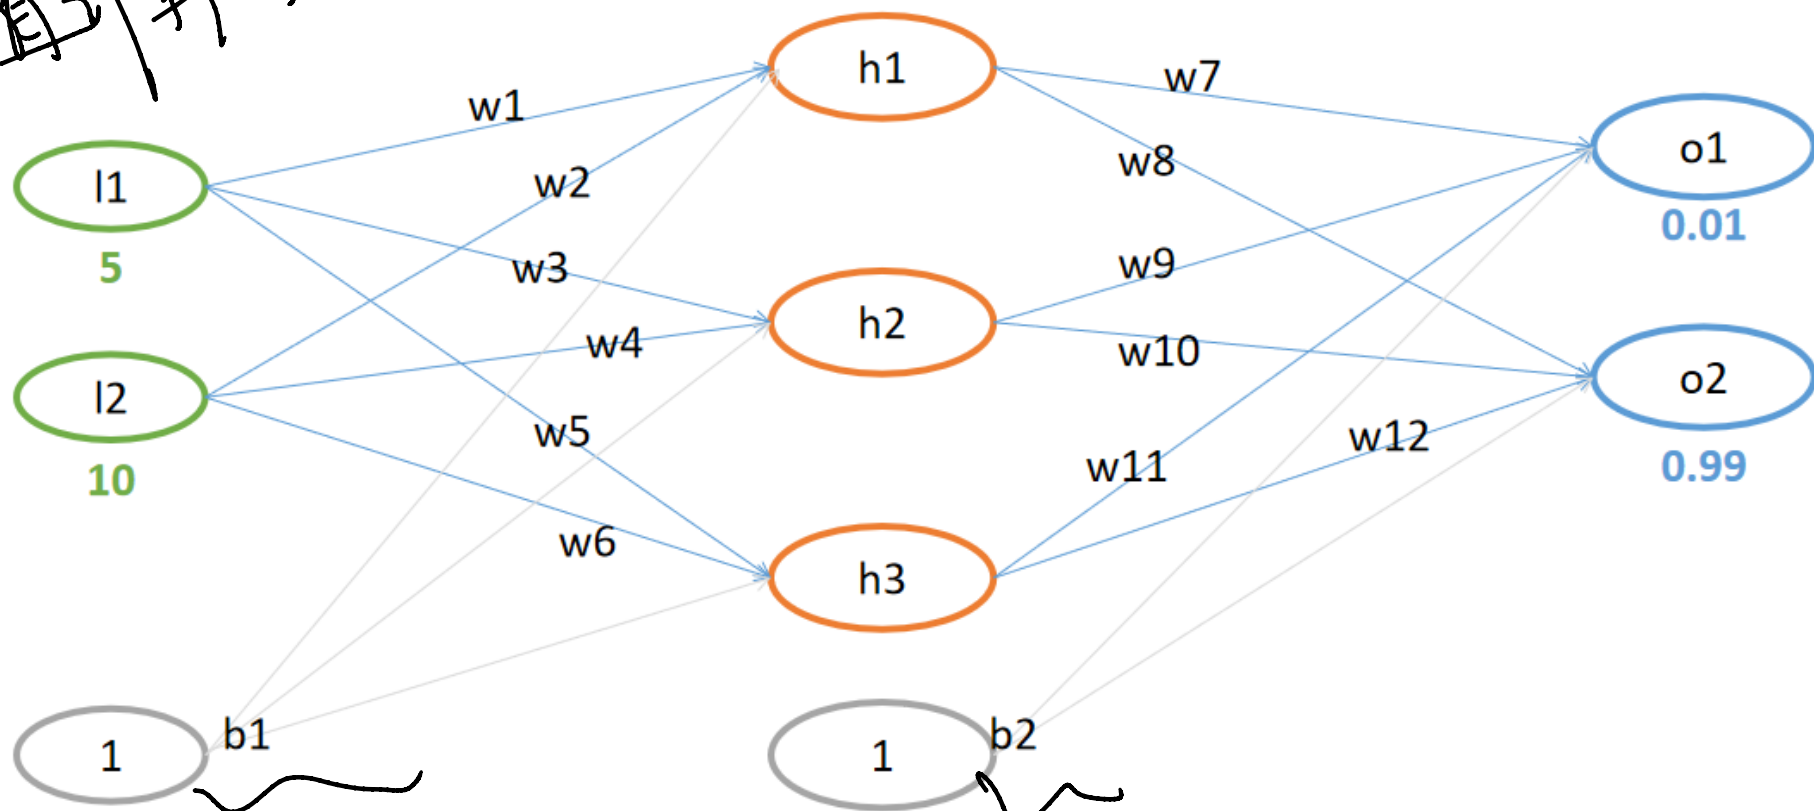
$$\Delta \omega_{jk} = -\eta \frac{\partial E}{\partial \omega_{jk}} \quad j = 0, 1, 2, \dots, m; \quad \kappa = 1, 2, \dots, \ell$$

$$\Delta v_{ij} = -\eta \frac{\partial E}{\partial v_{ij}} \quad i = 0, 1, 2, \dots, n; \quad j = 1, 2, \dots, m$$



## BP算法例子

正向计算，反向值更新参数



$$w = (0.1, 0.15, 0.2, 0.25, 0.3, 0.35, 0.4, 0.45, 0.5, 0.55, 0.6, 0.65)$$

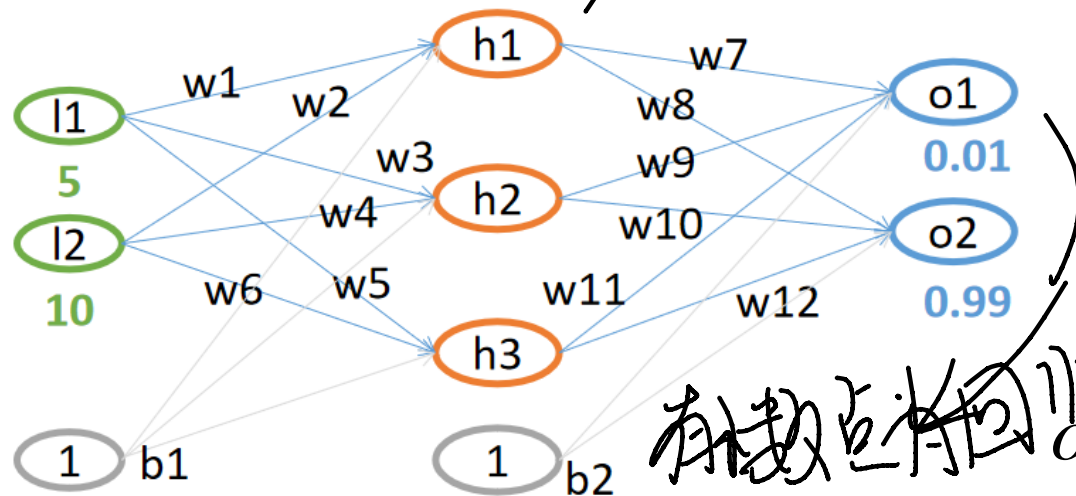
$$b = (0.35, 0.65)$$



# BP算法例子-FP过程

每层共用一个偏置

是偏置



$$net_{h1} = w_1 * l_1 + w_2 * l_2 + \underline{b_1 * 1}$$

$$net_{h1} = 0.1 * 5 + 0.15 * 10 + 0.35 * 1 = 2.35$$

$$out_{h1} = \frac{1}{1 + e^{-net_{h1}}} = \frac{1}{1 + e^{-2.35}} = 0.912934$$

有数据点回归问题

$$out_{h2} = 0.979164 \quad out_{h2} = 0.995275$$

$$b = (0.35, 0.65) \quad net_{o1} = w_7 * out_{h1} + w_9 * out_{h2} + w_{11} * out_{h3} + b_2 * 1$$


$$w = \begin{pmatrix} 0.1, 0.15, 0.2, 0.25, 0.3, 0.35, \\ 0.4, 0.45, 0.5, 0.55, 0.6, 0.65 \end{pmatrix} \quad net_{o1} = 0.4 * 0.912934 + 0.5 * 0.979164 + 0.6 * 0.995275 = 2.1019206$$

$$out_{o1} = \frac{1}{1 + e^{-net_{o1}}} = \frac{1}{1 + e^{-2.1019206}} = 0.891090 \quad out_{o2} = 0.904330$$

$$E_{total} = E_{o1} + E_{o2} = \frac{1}{2} (0.01 - 0.891090)^2 + \frac{1}{2} (0.99 - 0.904330)^2 = 0.391829$$

## BP算法例子-FP过程

求权值, 求导, 方程少, 未知数多, 找偏导  
 $(\frac{1}{1+e^{-x}})' = x/(1-x)$



$$E_{o1} = \frac{1}{2} (\text{target}_{o1} - \text{out}_{o1})^2$$

$$E_{total} = E_{o1} + E_{o2}$$

$$\frac{\partial E_{total}}{\partial w_7} = \frac{\partial E_{total}}{\partial \text{out}_{o1}} * \frac{\partial \text{out}_{o1}}{\partial \text{net}_{o1}} * \frac{\partial \text{net}_{o1}}{\partial w_7}$$

$$\frac{\partial E_{total}}{\partial \text{out}_{o1}} = 2 * \frac{1}{2} (\text{target}_{o1} - \text{out}_{o1})^{2-1} * -1 + 0 = -(0.01 - 0.891090) = 0.88109$$

~~激活函数~~

$$\text{out}_{o1} = \frac{1}{1 + e^{-\text{net}_{o1}}}$$

$$\frac{\partial \text{out}_{o1}}{\partial \text{net}_{o1}} = \text{out}_{o1} (1 - \text{out}_{o1}) = 0.891090 (1 - 0.891090) = 0.097049$$

$$\text{net}_{o1} = w_7 * \text{out}_{h1} + w_9 * \text{out}_{h2} + w_{11} * \text{out}_{h3} + b_2 * 1$$

$$\frac{\partial \text{net}_{o1}}{\partial w_7} = 1 * \text{out}_{h1} * w_7^{(1-1)} + 0 + 0 + 0 = 0.912934$$

$$\frac{\partial E_{total}}{\partial w_7} = 0.88109 * 0.097049 * 0.912934 = 0.078064$$

## BP算法例子-FP过程

$$\frac{\partial E_{total}}{\partial w_1} = \frac{\partial E_{total}}{\partial out_{h1}} * \frac{\partial out_{h1}}{\partial net_{h1}} * \frac{\partial net_{h1}}{\partial w_1} = \left( \frac{\partial E_{o1}}{\partial out_{h1}} + \frac{\partial E_{o2}}{\partial out_{h1}} \right) * \frac{\partial out_{h1}}{\partial net_{h1}} * \frac{\partial net_{h1}}{\partial w_1}$$

$$\frac{\partial E_{o1}}{\partial out_{h1}} = \frac{\partial E_{o1}}{\partial out_{o1}} * \frac{\partial out_{o1}}{\partial net_{o1}} * \frac{\partial net_{o1}}{\partial out_{h1}} = -(\text{target}_{o1} - out_{o1}) * out_{o1} * (1 - out_{o1}) * w_7$$

$$\frac{\partial E_{o1}}{\partial out_{h1}} = -(0.01 - 0.891090) * 0.891090 * (1 - 0.891090) * 0.360968 = 0.030866$$

$$\frac{\partial E_{total}}{\partial w_1} = 0.011204$$

学习一般取 0.001, 太大了不稳定  
小些较好.

$$w_1^+ = w_1 + \Delta w_1 = w_1 - \eta \frac{\partial E_{total}}{\partial w_1} = 0.1 - 0.5 * 0.011204 = 0.094534$$

梯度

## BP算法例子-FP过程

$$w_1^+ = 0.094534$$

$$w_2^+ = 0.139069$$

$$w_3^+ = 0.198211$$

$$w_4^+ = 0.246422$$

$$w_5^+ = 0.299497$$

$$w_6^+ = 0.348993$$

$$w_7^+ = 0.360968$$

$$w_8^+ = 0.453383$$

$$w_9^+ = 0.458137$$

$$w_{10}^+ = 0.553629$$

$$w_{11}^+ = 0.557448$$

$$w_{12}^+ = 0.653688$$

$$b_1 = 0.35$$

$$b_2 = 0.65$$

## BP算法例子-FP过程

- 第10次迭代结果:

$$O = (0.662866, 0.908195)$$

- 第100次迭代结果:

$$O = (0.073889, 0.945864)$$

- 第1000次迭代结果:

$$O = (0.022971, 0.977675)$$

① 损失函数归0

应该停止,

否则会导致过拟合。

② 损失函数不变

一直振荡

$$w^0 = \begin{pmatrix} 0.1, 0.15, 0.2, 0.25, \\ 0.3, 0.35, 0.4, 0.45, \\ 0.5, 0.55, 0.6, 0.65 \end{pmatrix}$$

$$w^{1000} = \begin{pmatrix} 0.214925, 0.379850, 0.262855, \\ 0.375711, 0.323201, 0.396402, \\ -1.48972, 0.941715, -1.50182, \\ 1.049019, -1.42756, 1.151881 \end{pmatrix}$$

## 神经网络之DNN问题

- 一般来讲，可以通过增加神经元和网络层次来提升神经网络的学习能力，使其得到的模型更加能够符合数据的分布场景；但是实际应用场景中，神经网络的层次一般情况不会太大，因为太深的层次有可能产生一些求解的问题。
- 在DNN的求解中有可能存在两个问题：**梯度消失**和**梯度爆炸**；我们在求解梯度的时候会使用到链式求导法则，实际上就是一系列的连乘，如果每一层都小于1的话，则梯度越往前乘越小，导致梯度消失，而如果连乘的数字在每层都是大于1的，则梯度越往前乘越大，导致梯度爆炸。

**THANKS!**